

PandaX-4T run10972

数据处理方法报告

从上游标量 TXT 到样本外能量估计的完整处理记录

报告回答的问题

数据怎样被读取、检查、划分和转换？

校正参数和 S1/S2 权重怎样学习，又怎样避免测试信息泄漏？

每个事件最终怎样得到一条可评价的样本外（OOF）能量估计？

4500

保留事件

8

固定白名单字段

2

文件分组检验

本报告的边界

本报告记录的是本项目实际执行的处理方法，不把当前 TXT 称为未处理波形，也不把相对能量宽度解释成绝对能标。原始数据分布见《原始数据报告》；模型表现与物理解读见完整技术报告。

报告人：范子恒

数据：run10972

日期：2026 年 7 月 17 日


实现：Python + LaTeX

1 处理边界与总流程

当前输入文件为

`light_ana_run10972_finalSS_Egt2MeV_scalar.txt`。

它是一张上游生成的事件级标量表，而不是探测器原始波形。处理时始终把原文件作为只读输入；程序把新结果写入单独输出目录，不覆盖 TXT，也不回写任何列。



固定的开发白名单

$$\left\{ \begin{array}{l} \text{runNumber, fileNumber, eventNumber,} \\ \text{qS1_max, qS2B_max, dt,} \\ \text{xS2T_max, yS2T_max} \end{array} \right\}.$$

除这 8 列外，主独立处理链不读取已有校正量、寿命校正量、ub/stretch/MCPAF 等派生分支，也不读取不明含义的 cut flag。

为什么要限制输入？

目标不是复现别人已有的重建，而是只依赖基本观测量建立可审计的基线。白名单同时防止“无意中已经包含旧校正的信息”，使每一步改善都能追溯到本项目自己的处理。

没有做的事情

没有恢复波形、没有重新找峰、没有定义新的事件质量 cut、没有根据单事件能量残差删除“难看事件”，也没有利用假定的已知源能量做绝对刻度。

2 读取、审计与固定事件集合

2.1 读取方式

两个独立处理脚本都使用制表符读取，并通过 `usecols` 在入口处限制列：

```
df = pandas.read_csv(DATA_PATH,
    sep="\t", usecols=ALLOWED_COLUMNS)
```

这一步不会把 188 个字段全部送入模型。事件身份使用

(runNumber, fileNumber, eventNumber)

三元组；它也是后续将 OOF 结果与输入重新对齐的唯一键。

2.2 入口审计规则

检查	实际规则	失败时的处理
字段存在	8 个白名单字段必须都可读取	立即报错，不猜测替代列
数值有限	白名单数值必须不是 NaN 或 $\pm\infty$	基本实验矩阵直接终止
信号为正	$q_{S1} > 0$ 且 $q_{S2B} > 0$	直接终止，不静默删行
身份唯一	三元组不得重复	直接终止
事件数量	入口后仍为 4500 个事件	写入元数据并核对
输入指纹	对完整 TXT 计算 SHA-256	用于复现实验版本

当前数据通过上述检查：4500 个事件全部进入处理；不同 `fileNumber` 为 985 个；输入指纹为

```
d026e0e30bf6d6af44f3b04848c96815bbbc062cf13f7017e2422dc054cf9d0b
```

2.3 为什么没有继续施加 cut?

数据中虽存在若干 cut flag，但其取值方向和物理含义尚未由可靠文档确认；文件名中的 `finalSS` 与 `Egt2MeV` 还暗示上游可能已经做过单散射和阈值预选。因此本项目采用下面的保守原则：

$$\mathcal{D}_{\text{analysis}} = \{i : \text{白名单字段有限, 且 } q_{S1,i} > 0, q_{S2B,i} > 0\}, \quad |\mathcal{D}_{\text{analysis}}| = 4500.$$

“全部保留”不等于“原始采集效率为 100%”

这里的 100% 保留率只针对已经出现在当前 TXT 中的 4500 行。由于上游选择未知，不能据此推断 DAQ 触发效率、单散射效率或 $E > 2 \text{ MeV}$ 的真实接受率。

入口阶段的最终产物

得到一个固定、不随候选方法改变的事件集合。后续任何方法的宽度差异都不是因为删掉了不同事件，而是因为它们给同一批 4500 个事件产生了不同的能量估计。

3 派生坐标与训练内归一化

3.1 只从白名单构造两个坐标

在逐通道物理修正链中，漂移时间和横向径向坐标定义为

$$t_d = \frac{dt}{1000} \quad [\mu s], \quad (1)$$

$$r^2 = x^2 + y^2, \quad x = xS2T_max, \quad y = yS2T_max. \quad (2)$$

代码直接用 r^2 拟合响应，不先开平方。基本实验矩阵保留 dt 的原始数值尺度，再用训练集尺度标准化；这与把单位换成 μs 后再标准化只相差一个常数，不改变低阶多项式所表达的响应族。

fileNumber 的角色

在主处理链中，**fileNumber** 用于：(1) 把同一文件中的事件放在同一折；(2) 画获取时间方向的事后诊断；(3) 以文件为单位做 bootstrap。它不是能量、深度或位置坐标。仅 A5 诊断候选显式试验线性文件漂移，并未把它当作最终默认校正。

3.2 两条处理链使用的中心量不同

处理链	训练中心	用途
逐通道物理修正矩阵	稳健峰中心 c_{peak}	分别归一化校正后的 S1、S2，并确定最终能量尺度
基本响应实验矩阵	训练集样本中位数	归一化原始 S1、S2；响应面目标仍为分箱后的对数能量中位数

3.3 稳健峰中心怎样计算？

对训练样本中的正有限量 q ，代码执行以下固定步骤：

1. 转到 $u = \ln q$ ，仅在 u 的 1%–99% 分位范围内做 80 个等宽直方箱；
2. 用宽度参数 $\sigma = 1.25$ 个箱的高斯核平滑计数，取最高箱中心作为对数众数 u_{mode} ；
3. 在 $|\ln q - u_{mode}| \leq \ln(1.20)$ 的固定乘法窗口内取中位数；
4. 若窗口内样本少于 20 个或少于总样本的 10%，则退回全部正有限样本的中位数。

这个量只估计一组样本的中心，不是把单事件残差作为监督标签进行回归。

所有中心与尺度都只从训练数据得到

外层测试折的中位数、峰位置、坐标范围和响应趋势均不参与学习。对测试事件应用的每个数字都已经由相应外层训练集冻结。

这一页的核心

派生变量只有 t_d 和位置坐标；归一化的作用是让 S1 与 S2 进入可比较的无量纲尺度，而不是把相对能量变成 MeV。

4 按文件分组的嵌套验证

随机按事件拆分会把同一获取文件中的相似条件同时放进训练和测试。为降低这种泄漏，所有折都由 `fileNumber` 决定，同一文件内的事件绝不跨折。

4.1 两种外层划分

交错文件折: `file_mod5`

$$k(f) = f \bmod 5.$$


相邻文件通常分到不同折，更接近“在整个 run 内插值”的检验。

连续文件块: `file_block5`

将排序后的 985 个不同文件号等分成 5 个连续块，更敏感于随获取时间发生的漂移与外推不稳定。

折	<code>fileNumber</code> 范围	文件数	事件数	含义
0	0–199	197	869	最早连续块
1	200–397	197	939	连续块
2	398–600	197	928	连续块
3	601–801	197	873	连续块
4	802–999	197	891	最晚连续块

4.2 外层测试与内层选择



对第 k 个外层折，测试集合记为 $\mathcal{D}_k$ ，其余文件为 $\mathcal{D}_{-k}$ 。所有响应模型、中心量和组合权重都只在 $\mathcal{D}_{-k}$ 内选择；选好后在 $\mathcal{D}_{-k}$ 上重拟合，再一次性应用到 $\mathcal{D}_k$ 。五个测试折拼接后：

$$\hat{E}_i^{\text{OOF}} = \hat{E}^{(-k(i))}(x_i), \quad i = 1, \dots, 4500.$$

OOF 的直观含义

每个事件都得到一个能量值，但生成这个值的模型从未见过该事件所属的测试文件。这样得到的总体宽度比“在同一批数据上拟合又评价”更接近对新文件的真实表现。

5 逐通道物理修正矩阵

这条处理链先分别校正 S1 与底部 S2，再组合为相对能量。候选在运行前固定，所有候选保留同样的 4500 个事件。

5.1 固定候选

候选	S1 处理	S2B 处理
A0 raw	不校正	不校正
A1 s2_lifetime	不校正	指数寿命趋势
A2 s1_dt_r2	先 t_d 响应，再 r^2 响应	不校正
A3 s2_lifetime_r2	不校正	先寿命，再 r^2 响应
A4 both	先 t_d ，再 r^2	先寿命，再 r^2
A5 both_file_linear	A4 后增加线性文件漂移	A4 后增加线性文件漂移

5.2 分箱响应校正

对训练数据中的某个信号 q 和坐标 z ，将 z 按分位数划成 5 个近似等统计量箱。第 j 箱和全局稳健中心分别为 c_j 、 c_0 ，定义相对响应

$$\rho_j = \frac{c_j}{c_0}. \quad (3)$$

在各箱坐标中位数之间对 $\ln \rho_j$ 线性插值，并把对数响应限制在 $[\ln 0.5, \ln 2]$ ，得到 $\hat{\rho}(z)$ 。校正为

$$q^{\text{corr}} = q \exp[-\ln \hat{\rho}(z)] = \frac{q}{\hat{\rho}(z)}. \quad (4)$$

若有多个步骤，后一步只拟合前一步校正后的训练信号。例如 A4 的 S1 顺序为

$$q_{\text{S1}} \rightarrow q_{\text{S1}}^{(t_d)} \rightarrow q_{\text{S1}}^{(t_d, r^2)}.$$

5.3 S2 寿命形式与文件漂移诊断

S2 寿命步骤只对 5 个粗分箱的稳健中心做加权直线拟合：

$$\ln c(t_d) = a + b(t_d - t_0), \quad b \in \left[-\frac{1}{200 \mu\text{s}}, 0\right]. \quad (5)$$

负斜率对应电子随漂移时间损失；响应因子限制在 $[0.5, 2.0]$ ，防止稀疏边界外推爆炸。A5 的文件漂移采用相同的对数线性思想，但把全 run 的响应变化限制在约 $\pm 30\%$ ；它是稳定性试验，不是默认的物理校正。

候选比较的统计身份

A0–A5 都各自生成了完整 OOF 预测，但在看过这些 OOF 结果后再比较六个候选，仍属于探索性模型比较，不是额外一层完全独立的最终检验。正式结论需要冻结候选后到另一个 run 验证。

6 通道组合、权重选择与能量尺度

6.1 逐通道归一化

对某个外层训练折拟合好通道模型后，计算训练内稳健中心 c_1 、 c_2 ：

$$s_1 = \frac{q_{S1}^{\text{corr}}}{c_1}, \quad s_2 = \frac{q_{S2B}^{\text{corr}}}{c_2}. \quad (6)$$

同一组 c_1, c_2 随模型一起冻结并应用到测试折。

6.2 正权重组合

逐通道物理修正矩阵使用凸组合

$$e_\alpha = \alpha s_1 + (1 - \alpha)s_2, \quad \alpha \in \{0.10, 0.15, \dots, 0.90\}. \quad (7)$$

对每个外层折和每个候选，先在内层训练数据拟合通道响应，再在内层验证数据扫描 17 个 α 。交错文件折把“外层折的下一折”作为内层验证；连续文件块优先使用外层测试块之前的相邻块（块 0 例外使用块 1）。选择顺序是：

$$\min(R_{68}^{\text{val}}, R_{90}^{\text{val}}, \alpha),$$

即先最小化验证集 R_{68} ，若相同再比较 R_{90} ，仍相同则取较小 α 。



6.3 最终相对能量

在外层训练全集上计算

$$s_E = c_{\text{peak}}(e_\alpha^{\text{train}}), \quad \hat{E}^{\text{OOF}} = \frac{\alpha s_1 + (1 - \alpha)s_2}{s_E}. \quad (8)$$

因此最终数值的峰中心约为 1，是**无量纲相对能量**。没有单线能量真值和增益常数时，它不能直接标成 MeV。

这里的 α 是什么？

α 是在已经分别归一化的 S1、S2 通道之间选择的统计组合权重。它依赖中心定义和公式写法，不等同于光产额、电子产额、 g_1 、 g_2 或反相关直线斜率。

测试折从未参与的量

响应图、寿命斜率、S1/S2 中心、 α 和最终尺度 s_E 全部来自训练侧。测试折只提供白名单观测测量并接受冻结变换。

7 基本响应实验矩阵：第二条独立处理链

为了检查“先组合再做低自由度响应校正”是否更合适，项目还实现了另一条独立嵌套链。它与上一节的公式不同，参数不能直接横向解释。

7.1 原始组合与权重网格

基本矩阵在每个训练折内计算 S1、S2 中位数 m_1, m_2 ，定义

$$E_{\text{raw}} = \frac{q_{\text{S2B}}}{m_2} + \alpha \frac{q_{\text{S1}}}{m_1}, \quad \alpha > 0. \quad (9)$$

α 网格由 0.05 到 20 的 15 个对数等距点，以及 0.75, 1.0, 1.5 组成。每个方法的 α 都由外层训练内的轮换验证单独选择。

7.2 预先定义的几个方法

方法	复杂度	处理顺序
raw	0	只做正权重 S1/S2 组合
dt_quad	3	一维漂移时间二次响应
r2_quad	3	一维 r^2 二次响应
dt_r2_joint	6	t_d 与 r^2 联合二次响应面
dt_then_r2	6	先漂移时间，再 r^2
r2_then_dt	6	先 r^2 ，再漂移时间
xy_quad	6	x 、 y 联合二次响应面
dt_then_xy	9	先漂移时间，再 x - y
dt_r2_then_xy	12	联合 t_d - r^2 后再修正 x - y 残余

7.3 响应面怎样拟合？

坐标先用训练中位数和训练尺度标准化；尺度优先取 5%–95% 分位差的一半。随后：一维坐标划 10 个分位箱，多维坐标每维划 5 个分位箱；只保留至少 12 个训练事件的网格单元。对每个单元只取坐标中位数、对数能量中位数和事件数，再拟合低阶多项式：

$$\begin{aligned} \phi_{1D}(z) &= (1, z, z^2), \\ \phi_{ab}(a, b) &= (1, a, b, a^2, b^2, ab). \end{aligned}$$

以 $\sqrt{n_{\text{cell}}}$ 加权、带 10^{-8} 的极小岭项求解系数 β 。令

$$\Delta(z) = \phi(z)^T \beta - \text{median}_{\text{train}}(\ln E), \quad E^{\text{corr}} = E \exp[-\Delta(z)].$$

Δ 被训练预测的 1%–99% 范围和 $[-0.30, 0.30]$ 双重限制，避免稀疏区域产生过大校正。

嵌套方法选择

每个外层折先在训练侧为九个国家方法分别选 α ；再找内层 R_{68} 最小的方法。凡与最优值相差不超过 0.0005（即 0.05 个百分点）的候选，优先选择复杂度更低者，形成 **nested_winner**。外层测试仍不参与选择。

8 OOF 汇总、评价与不确定度

8.1 全事件非参数宽度

所有外层测试预测拼接后，先以 OOF 中位数 M 归一化： $y_i = \hat{E}_i^{\text{OOF}}/M$ 。核心与较宽尾部指标定义为

$$R_{68} = \frac{Q_{84.135\%}(y) - Q_{15.865\%}(y)}{2}, \quad (10)$$

$$R_{90} = \frac{Q_{95\%}(y) - Q_{5\%}(y)}{2}. \quad (11)$$

这两个量都使用全部有限 OOF 事件，不选拟合窗，也不先去掉尾部。代码还记录

$$f_{20} = \Pr(y < 0.8 \text{ 或 } y > 1.2),$$

$$f_{2R_{68}} = \Pr(|y - 1| > 2R_{68}).$$

为什么不用单一高斯 σ/μ ?

当前分布可能有非高斯尾部、选择边界和空间不均匀。分位数宽度不需要先假设峰形，且 R_{68} 与 R_{90} 能分别提示核心与更宽尾部是否同时改善。它们是“观测分布宽度”，不能自动等同于探测器本征分辨率。

8.2 事后响应诊断

冻结 OOF 预测后，再分别按 t_d 、 r^2 和 **fileNumber** 分箱，计算各箱中心相对于全局中心的变化。这一步只回答“测试侧是否仍有残余趋势”，诊断结果从不反馈到响应图或权重。

8.3 配对文件 bootstrap

以 985 个不同 **fileNumber** 为重采样单元，进行 1000 次有放回抽样。同一次复制中，各候选使用完全相同的抽中文件，计算

$$\Delta R_{68} = R_{68}^{\text{candidate}} - R_{68}^{\text{raw}}, \quad \Delta R_{90} = R_{90}^{\text{candidate}} - R_{90}^{\text{raw}}.$$

报告 2.5%、50%、97.5% 分位数作为条件区间。

bootstrap 区间的准确含义

每次重采样只重组已经冻结的 OOF 预测，没有重新训练响应图、权重和方法选择。因此它衡量“当前冻结流程对文件组成的敏感性”，不包含完整训练流程的不确定度。

8.4 一条结果怎样回到原事件?

输出表保留身份三元组、划分方案、外层折、候选或方法名、选择的权重和 OOF 能量。因而任意异常点都可以回查到原 TXT 的具体事件，而不依赖行号猜测。

9 输出文件、复现顺序与方法结论

9.1 主要脚本与复现顺序

在项目根目录依次运行：

```
$PY = "$env:LOCALAPPDATA\Programs\Python\Python313\python.exe"
& $PY .\energy_resolution_analysis\channel_physics_matrix.py
& $PY .\energy_resolution_analysis\basic_experiment_matrix.py
& $PY .\energy_resolution_analysis\robust_peak_evaluation.py --input ...
```

前两个脚本生成主 OOF 处理结果；第三个脚本只做额外峰形适用性诊断，不改变已有 OOF 预测。当前电脑未把 Python 加入 PATH，所以上面记录了实际解释器；复现时需要 Python 3.10+ 及 NumPy、pandas、SciPy、Matplotlib。

输出位置	内容
channel_physics_outputs/	A0–A5 的逐事件 OOF、外层折指标、内层 α 扫描、响应诊断、配对文件 bootstrap、模型参数 JSON
basic_matrix_outputs/	九个方法和 nested_winner 的 OOF、候选分数、内层选择、折稳定性、文件诊断、元数据与 bootstrap
independent_outputs/	早期独立尝试，作为失败和不稳定性记录保留，不作为当前主结论
outputs/	使用更多派生分支的历史探索基准，不属于当前“只依赖基本变量”的主开发链

9.2 处理过程已经做到什么？

已完成

- 建立了从只读 TXT、固定事件集合到逐事件 OOF 相对能量的可追溯链路；
- 用字段白名单隔离了既有重建分支，且没有通过额外 cut 人为收窄分布；
- 用按文件分组的两种拆分检查内插表现和连续时间块稳定性；
- 将响应学习、权重选择、尺度确定全部限制在训练侧；
- 同时保留改善方法和负结果，并给出全事件宽度、尾部与文件重采样不确定度；
- 保存输入指纹、模型参数、折标签和事件身份，支持后续复查与复现。

9.3 仍然不能声称什么？


当前限制

- 只有一个 run，且源类型、单线能量真值和上游 $E > 2 \text{ MeV}$ 预选细节未知；
- 当前结果是相对能量重建，尚未完成 MeV 绝对标定；
- 候选在当前 OOF 上比较后仍带探索性，正式验证应冻结流程并使用独立 run；
- 文件 bootstrap 没有逐次重训，不能代表完整流水线不确定度；
- 空间覆盖明显不均匀，响应图可能同时吸收真实探测器响应和样本组成变化。

方法结论与独立验证清单

当前已经建立的处理资产

本项目已经形成了“只读输入 → 固定白名单 → 文件级嵌套验证 → 训练内响应学习与权重选择 → OOF 汇总 → 文件重采样”的完整链路。事件身份、折标签、模型参数和输入指纹均被保留，因此每个结果都可以回查。



独立验证前需要补齐的四项信息

项目	需要补齐的内容	原因
上游选择	Egt2MeV 的估计量、阈值和筛选顺序；最好提供未做该预选的数据	判断低能尾和事件成员是否已被塑形
独立样本	同类源、相近条件但未参与开发的另一个 run	检验方法能否跨文件和跨 run 迁移
冻结模型	保存用完整开发 run 拟合的最终参数，并锁定 Python 与依赖版本	让新 run 真正做到“只应用、不调参”
物理元数据	源类型与目标线、 $dt/x/y$ 定义、cut 语义、饱和范围、 g_1/g_{2B}	支持绝对能标与物理解读

建议的下一步

冻结最简单且在两种文件拆分下都稳定的方案；获取另一个校准 run 或未做能量阈值预选的数据；在不改方法、不重选参数的条件下做真正独立验证，再讨论绝对能标和“分辨率提高”的物理结论。

当前最严谨的一句话

在 run10972 的未知 $E > 2 \text{ MeV}$ 预选样本上，仅使用基础变量的独立处理链，在两种按文件划分的 OOF 验证中显示了非参数宽度改善；正式能量分辨率仍需无阈值样本和独立 run 验证。